

UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA



Curso : Data Mining Tools (CC209)
Sección : 17496
Docente : Carlos Fernando Montoya Cubas
Proyecto : Predicción de fuga de clientes

Integrantes

- u202310688 - Basas Requena, Joaquin Alonso
- u20191e443 - Chavez Merino, Cielo Luwidka
- u20231b834 - Gamero Vera, Rodrigo Alonso
- u202218498 - Rojas Cuadros, Fabian Marcelo

Ciclo 2026-2

Índice

RESUMEN	3
1 DEFINICIÓN DEL PROBLEMA	4
1.1 Contexto y necesidad	4
1.2 Unidad de análisis, pregunta y tipo de problema	4
1.3 Utilidad esperada y criterios de utilidad	4
2 DATASET Y PROCEDENCIA	5
2.1 Variables	5
2.2 Limitaciones conocidas	6
3 ANÁLISIS EXPLORATORIO (EDA)	6
3.1 Variable objetivo	7
3.2 Tipo de contrato	7
3.3 Antigüedad	8
3.4 Cargos mensuales y soporte técnico	8
3.5 Método de pago	9
3.6 Hallazgos que condicionan la preparación	10
4 CALIDAD Y PREPARACIÓN DE DATOS	10
4.1 Valores faltantes y duplicados	10
4.2 Tipos de datos y categorías	10
4.3 Reglas lógicas y de negocio	11
4.4 Outliers y valores extremos	11
4.5 Transformaciones realizadas	11
5 SEPARACIÓN DE DATOS Y CONTROL DE LEAKAGE	12
5.1 Estrategia 70/15/15 estratificada	12
5.2 Verificaciones anti-fuga	12
5.3 ¿Son comparables las particiones?	12
6 FLUJO REPRODUCIBLE DE PREPROCESAMIENTO	13
6.1 Verificaciones del <i>pipeline</i>	13
7 BASELINES, MODELOS Y EVALUACIÓN	14
7.1 Baselines	14
7.2 Métricas	14
7.3 Modelos	14
7.4 Resultados en validación	15
7.5 ¿Diferencias reales o ruido?	15
7.6 Evaluación final en <i>test</i>	16
7.7 Simulación económica	16
8 ESTADO DEL PROYECTO Y PLAN HACIA EL TF1	18
8.1 Principales hallazgos	18
8.2 Problemas no resueltos y limitaciones	18
8.3 Plan hacia el TF1	19

9	DECISIONES DE HERRAMIENTAS	20
10	DECLARACIÓN DE USO DE IA GENERATIVA	21
	ANEXOS	22
	REFERENCIAS	23

RESUMEN

Este informe presenta el proyecto integrador del curso Data Mining Tools. Nos enfocamos en la fuga de clientes de una empresa de telecomunicaciones, con una pregunta central: qué clientes tienen mayor probabilidad de cancelar su servicio y qué características se asocian con ese riesgo.

Trabajamos con un conjunto de datos público de 7,043 clientes, obtenido de la plataforma Kaggle. Primero revisamos la calidad de los datos y separamos la información en tres partes (entrenamiento, validación y prueba), para que la evaluación final fuera honesta y el modelo no pudiera aprovechar información que no le corresponde.

El análisis exploratorio mostró que el tipo de contrato es la característica más asociada con la fuga: cancela el 42.7 % de los clientes con contrato mensual frente al 2.8 % de quienes tienen contrato de dos años. También mostró que la fuga se concentra en los primeros meses de antigüedad y que solo uno de cada cuatro clientes cancela, por lo que acertar “en general” no basta para juzgar un modelo.

Luego construimos dos modelos de predicción y los comparamos entre sí y contra dos reglas simples, midiendo cuántas fugas detecta cada uno y cuántas alertas resultan falsas.

El modelo seleccionado, un Random Forest, detecta el 70.5 % de las fugas en los datos de prueba, frente al 43.8 % de la mejor regla simple, y alcanza un PR-AUC de 0.670 frente a 0.400. La diferencia frente al otro modelo evaluado, una regresión logística, es mínima, por lo que la selección es preliminar.

Finalmente, señalamos las limitaciones del trabajo, como que la meta de detección que nos propusimos (75 %) no se alcanza en la prueba final y que los costos usados en la simulación económica son supuestos del grupo, y presentamos el plan para mejorar la solución en la siguiente etapa.

Palabras clave: fuga de clientes, clasificación binaria, análisis exploratorio, desbalance de clases, Random Forest.

1. DEFINICIÓN DEL PROBLEMA

1.1. Contexto y necesidad

En los servicios por suscripción, cada cliente que cancela representa facturación recurrente que deja de percibirse. Una empresa puede intentar retener a sus clientes mediante descuentos o beneficios, pero aplicar esas acciones sobre toda la cartera resulta costoso y alcanza a muchos clientes que no pensaban irse. Por ello, antes de intervenir conviene saber a quiénes dirigirse.

El aprendizaje automático permite estimar, para cada cliente, la probabilidad de cancelación a partir de su perfil, sus servicios y su contrato. Sin embargo, un modelo con buenas métricas generales no basta: cuando la clase de interés es minoritaria, la exactitud puede ser alta sin detectar ninguna fuga, y las curvas de precisión y exhaustividad resultan más informativas que la curva ROC (Saito y Rehmsmeier, 2015). Es necesario, además, comparar el modelo con reglas simples y declarar con claridad qué no puede concluirse.

Se identifica, por tanto, una necesidad concreta: **identificar a los clientes con mayor riesgo de fuga** para priorizar acciones de retención, en lugar de aplicarlas de manera indiscriminada.

1.2. Unidad de análisis, pregunta y tipo de problema

La **unidad de análisis** es un cliente con contrato individual (una fila del conjunto de datos); cada cliente aparece una sola vez. La **pregunta principal** del proyecto es:

¿Qué clientes presentan mayor probabilidad de fuga y qué variables contractuales, de servicio y de facturación están asociadas con ese riesgo, de manera que puedan priorizarse intervenciones preventivas?

Tabla 1: Tipo de problema de Data Science

Componente	Tipo	Salida
Principal	Clasificación binaria supervisada con desbalance moderado	Probabilidad de fuga y clase predicha (1 = fuga, 0 = retención)

1.3. Utilidad esperada y criterios de utilidad

La solución busca ofrecer una **lista priorizada de clientes en riesgo**, con un nivel de acierto cuantificado, para orientar las campañas de retención. La Tabla 2 resume cuándo se considera útil el resultado. Estos criterios son metas internas del grupo, no requisitos impuestos por la rúbrica.

Tabla 2: Criterios de utilidad definidos por el grupo

Criterio	Umbral	Motivo
Mejora sobre los baselines	PR-AUC superior a 0.60, frente a una prevalencia de 0.265	Un modelo que no mejora una regla simple no aporta
Cobertura de riesgo	<i>Recall</i> de la clase fuga ≥ 0.75	Una fuga no detectada es el error más costoso
Utilidad económica	Valor neto simulado mayor que cero	Las alertas deben compensar el costo de los incentivos mal dirigidos

2. DATASET Y PROCEDENCIA

El conjunto de datos es *Telco Customer Churn*, una muestra de IBM Cognos Analytics publicada en Kaggle (BlastChar, s.f.), con clientes de una empresa de telecomunicaciones.

Tabla 3: Ficha del conjunto de datos

Característica	Valor
Observaciones $\times$ variables	$7,043 \times 21$
Período temporal	No aplica: corte transversal, sin fechas
Variable objetivo	Churn (1 = fuga, 0 = retención)
Distribución del objetivo	1,869 fugas (26.54 %) y 5,174 retenciones (73.46 %)
Valores nulos	0 declarados; 11 valores en blanco en TotalCharges
Identificadores únicos	7,043 customerID , ninguno repetido
Filas duplicadas exactas	0
Licencia	Pendiente de verificación en la fuente original

El conjunto de datos es adecuado para el problema porque combina variables de perfil, servicios contratados, contrato y facturación con un objetivo claramente definido, lo que permite recorrer el flujo completo de análisis exploratorio, preparación, modelamiento y evaluación.

2.1. Variables

La Tabla 4 describe las variables del conjunto de datos.

Tabla 4: Variables del conjunto de datos

Variable	Tipo	Descripción
customerID	Identificador	Identificador del cliente; se excluye del modelamiento

Variable	Tipo	Descripción
gender	Categórica binaria	Género del cliente
SeniorCitizen	Categórica binaria	1 si es adulto mayor, 0 si no
Partner, Dependents	Categórica binaria	Si tiene pareja y si tiene dependientes
tenure	Numérica discreta	Meses de antigüedad con la compañía (0 a 72)
PhoneService, MultipleLines	Categórica	Servicio telefónico y líneas múltiples
InternetService	Categórica	Tipo de internet: DSL, fibra óptica o ninguno
OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	Categórica	Servicios adicionales: sí, no o sin servicio de internet
Contract	Categórica	Tipo de contrato: mensual, un año o dos años
PaperlessBilling	Categórica binaria	Facturación electrónica
PaymentMethod	Categórica	Método de pago (cuatro categorías)
MonthlyCharges	Numérica (USD)	Cargo mensual (18.25 a 118.75)
TotalCharges	Numérica (USD)	Cargos acumulados; llega como texto
Churn	Binaria	Si el cliente canceló el servicio. Variable objetivo

2.2. Limitaciones conocidas

- **Corte transversal:** no hay historial transaccional ni fechas, por lo que no puede modelarse la evolución del cliente ni validarse el modelo con datos futuros.
- **Datos de muestra:** provienen de una muestra pública y no representan necesariamente a clientes de otros mercados o empresas.
- **Sin variables de experiencia:** no hay reclamos, calidad del servicio ni ofertas de la competencia; parte del comportamiento de fuga queda sin explicar.
- **Momento de la fuga:** la variable objetivo indica si el cliente canceló, pero no cuándo ni por qué.
- **Licencia:** está pendiente de verificación en la fuente original.

3. ANÁLISIS EXPLORATORIO (EDA)

El análisis exploratorio se organizó en torno a preguntas. En cada apartado se distingue lo que los datos muestran de lo que el grupo interpreta. Todas las relaciones descritas son asociaciones observadas en la muestra, no relaciones causales.

3.1. Variable objetivo




Figura 1: Distribución de la variable objetivo Churn

Fuente: elaboración propia a partir de *Telco Customer Churn*.

Nos enfocamos en el balance entre clases. Hallazgo: el 26.54 % de los clientes (1,869) canceló el servicio, frente al 73.46 % (5,174) que permanece. Interpretamos que la exactitud no puede ser la métrica guía: un clasificador que prediga siempre “no cancela” acertaría cerca del 73.5 % de las veces sin detectar una sola fuga.

3.2. Tipo de contrato




Figura 2: Tasa de churn por tipo de contrato

Fuente: elaboración propia.

Nos enfocamos en el compromiso contractual. Hallazgo: la tasa de fuga es de 42.7 % en contratos mensuales, 11.3 % en contratos de un año y 2.8 % en contratos de dos años. Interpretamos que el tipo de contrato es la variable más asociada con la fuga en esta muestra, pero el análisis no demuestra que cambiar el contrato de un cliente reduzca su probabilidad de cancelar.

3.3. Antigüedad




Figura 3: Antigüedad de los clientes según retención y fuga

Fuente: elaboración propia.

Nos enfocamos en los meses de antigüedad. Hallazgo: la mayor concentración de fugas se observa en los primeros meses. Los clientes con seis meses o menos son el 21.0 % de la base y reúnen el 41.9 % de las fugas; su tasa de fuga es de 52.9 %. Interpretamos que existe una etapa temprana de mayor riesgo, cuya causa el conjunto de datos no permite determinar. De este hallazgo surge el baseline heurístico del proyecto (contrato mensual y antigüedad de seis meses o menos).

3.4. Cargos mensuales y soporte técnico




Figura 4: Cargo mensual según churn y tasa de churn por tipo de internet y soporte técnico

Fuente: elaboración propia.

Nos enfocamos en el costo del servicio y en el soporte técnico. Hallazgo: quienes cancelan pagan una mediana de 79.65 dólares al mes, frente a 64.43 de quienes permanecen. Entre los clientes de fibra óptica, la fuga es de 49.4 % sin soporte técnico y de 22.6 % con

soporte técnico. Interpretamos que la combinación de internet, cargo mensual y soporte define un segmento de interés, pero no puede afirmarse que la falta de soporte cause la cancelación: quienes contratan soporte pueden diferir en otras características.

3.5. Método de pago




Figura 5: Tasa de churn por método de pago

Fuente: elaboración propia.

Nos enfocamos en la forma de pago. Hallazgo: el cheque electrónico presenta 45.3 % de fuga, frente a 19.1 % del cheque por correo, 16.7 % de la transferencia automática y 15.2 % de la tarjeta automática. Interpretamos que el método de pago aporta señal predictiva; podrían existir otras características del cliente relacionadas a la vez con la forma de pago y con la fuga.

3.6. Hallazgos que condicionan la preparación

Tabla 5: Hallazgos del EDA y decisión asociada

#	Hallazgo	Evidencia	Decisión
1	Clases desbalanceadas	26.54 % de fuga	PR-AUC como métrica principal; partición estratificada; <code>class_weight</code> balanceado
2	El contrato separa fuertemente los grupos	42.7 %, 11.3 % y 2.8 % de fuga	Conservar <code>Contract</code> como categoría
3	La fuga se concentra al inicio	41.9 % de las fugas con antigüedad ≤ 6 meses	Regla heurística como baseline
4	<code>TotalCharges</code> llega como texto	11 valores en blanco, todos con <code>tenure</code> = 0	Convertir a numérico y asignar 0 por regla lógica
5	Escalas numéricas distintas	<code>tenure</code> 0 a 72; <code>TotalCharges</code> 0 a 8,684.80	Estandarizar las variables numéricas
6	Categorías sin orden natural	16 variables categóricas	<i>One-hot encoding</i>
7	Asociación no es causalidad	Soporte técnico y método de pago	Interpretar como hipótesis, no como palancas demostradas

4. CALIDAD Y PREPARACIÓN DE DATOS

4.1. Valores faltantes y duplicados

El conjunto de datos no declara valores nulos. Sin embargo, `TotalCharges` contiene 11 registros con un espacio en blanco, lo que provoca que la columna se lea como texto. Al revisar esos registros se comprobó que los 11 tienen `tenure` = 0 y ninguno canceló: son clientes que aún no cierran su primer ciclo de facturación.

No existen filas duplicadas completas ni identificadores `customerID` repetidos.

Decisión: no se elimina ninguna fila. Los 11 vacíos se representan con `TotalCharges` = 0. Se trata de una regla lógica del negocio y no de una imputación estadística: asignarles la mediana de clientes consolidados habría falseado la situación de un cliente nuevo. Dentro del *pipeline* se mantiene una imputación por mediana solo como respaldo ante faltantes numéricos inesperados.

4.2. Tipos de datos y categorías

Así se trató cada tipo de variable:

- **Cargos acumulados:** `TotalCharges` se convirtió de texto a número.
- **Adulto mayor:** `SeniorCitizen` llega como 0 o 1 y se trata como categoría, porque identifica una condición y no una cantidad.
- **Variable objetivo:** `Churn` se convirtió de *Yes/No* a 1/0.
- **Identificador:** `customerID` no se usa para predecir.

No se encontraron categorías con espacios accidentales ni variantes de escritura, por lo que no hizo falta corregir ni agrupar categorías.

4.3. Reglas lógicas y de negocio

Se verificó la coherencia entre antigüedad y facturación. La única regla aplicada es la ya descrita: un cliente con antigüedad cero no tiene cargos acumulados. Los rangos de las variables numéricas son plausibles: la antigüedad va de 0 a 72 meses y el cargo mensual de 18.25 a 118.75 dólares.

4.4. Outliers y valores extremos

Se midió cuántos valores quedan fuera de 1.5 veces el rango intercuartílico (IQR) en las tres variables numéricas.

Tabla 6: Revisión de valores extremos por criterio IQR

Variable	Q1	Q3	Lím. inferior	Lím. superior	Casos fuera
<code>tenure</code>	9.00	55.00	−60.00	124.00	0
<code>MonthlyCharges</code>	35.50	89.85	−46.03	171.38	0
<code>TotalCharges</code>	398.55	3,786.60	−4,683.53	8,868.68	0

Fuente: notebook de análisis exploratorio.

Decisión: no se elimina ni se recorta ningún valor. Ninguna variable presenta casos fuera de los límites, y aun si los hubiera, un valor extremo puede corresponder a un cliente válido; solo se corregiría ante evidencia de inconsistencia.

4.5. Transformaciones realizadas

Antes de la partición solo se aplican correcciones de tipo y la regla lógica de `TotalCharges`, que no dependen de estadísticas del conjunto. No se crearon variables derivadas en el TP1. El escalado y la codificación se realizan dentro del *pipeline* descrito en la sección 6.

5. SEPARACIÓN DE DATOS Y CONTROL DE LEAKAGE

5.1. Estrategia 70/15/15 estratificada

Al no existir fechas, no cabe una división temporal. Se eligió una división aleatoria estratificada por la variable objetivo, con semilla fija (`random_state = 42`), para conservar la proporción de fuga en las tres particiones.

Tabla 7: Particiones de los datos

Partición	Filas	Proporción	Uso
<i>Train</i>	4,930	70 %	Ajustar transformaciones y modelos
<i>Validation</i>	1,056	15 %	Comparar modelos y seleccionar
<i>Test</i>	1,057	15 %	Evaluación final, una sola vez

Se optó por tres particiones porque la comparación entre modelos es una decisión, y tomarla con los mismos datos de la evaluación final daría una estimación optimista. Una vez elegido el modelo, se reentrena con *train* y *validation* y recién entonces se evalúa en *test*.

5.2. Verificaciones anti-fuga

- Cada cliente aparece una sola vez, por lo que ninguno queda repartido entre particiones.
- La división se hace **antes** de ajustar cualquier transformación estadística, y estas se calculan solo con los datos de entrenamiento.
- No se usa para predecir el identificador del cliente.
- La única corrección previa a la división es la regla lógica de `TotalCharges`, que no aprende ninguna estadística del conjunto.
- El *test* no se usa para ajustar ni para decidir; solo se mide en la evaluación final.

5.3. ¿Son comparables las particiones?

Tabla 8: Características de cada partición

Partición	n	Churn	Antigüedad	Cargo mensual	Contrato mensual
<i>Train</i>	4,930	26.53 %	29	70.57	54.8 %
<i>Validation</i>	1,056	26.52 %	27	70.75	56.7 %
<i>Test</i>	1,057	26.58 %	30	69.15	54.1 %

Antigüedad y cargo mensual se reportan como medianas (meses y dólares). Sí, las tres particiones son comparables: la tasa de fuga es prácticamente idéntica y la antigüedad, el

cargo mensual y la proporción de contratos mensuales son similares, por lo que ninguna favorece ni perjudica al modelo.

6. FLUJO REPRODUCIBLE DE PREPROCESAMIENTO

El preprocesamiento se implementó con `Pipeline` y `ColumnTransformer` de `scikit-learn` (Pedregosa et al., 2011), de modo que cada transformación quede vinculada al tipo de variable y se ajuste únicamente con los datos de entrenamiento.

Tabla 9: Transformación aplicada a cada grupo de variables

Grupo	Variables	Qué se hizo	Por qué
Numéricas	<code>tenure</code> , <code>MonthlyCharges</code> , <code>TotalCharges</code>	Imputación por mediana (respaldo) y <code>StandardScaler</code>	Para que ninguna variable pese más solo por sus unidades
Catóricas	Las 16 restantes, incluida <code>SeniorCitizen</code>	Imputación por moda (respaldo) y <code>OneHotEncoder</code>	No tienen orden natural y los modelos trabajan con números
Objetivo	<code>Churn</code>	Conversión a 1/0	Formato requerido por los modelos
No se usa	<code>customerID</code>	—	Es un identificador, no una característica predictiva

6.1. Verificaciones del *pipeline*

Tras la preparación, los datos quedan en 30 columnas numéricas y sin ningún valor vacío: 3 corresponden a las variables numéricas y 27 a las categorías codificadas. Para comprobar que no hubo fuga de información, se verificó que los promedios usados para estandarizar (32.47 meses de antigüedad y 64.95 dólares de cargo mensual) coinciden con los obtenidos solo con los datos de entrenamiento y no con los de todo el conjunto (32.37 y 64.76).

El flujo es reproducible porque usa una semilla fija (42), no falla si aparece una categoría que no estaba en el entrenamiento y se ejecuta completo con un solo comando (`python -m src.train_models`). Como riesgo, se comprobó que el resultado es sensible a la versión de `scikit-learn`, por lo que las versiones de las dependencias deben fijarse (sección 8.2).

7. BASELINES, MODELOS Y EVALUACIÓN

7.1. Baselines

Para responder si el modelo mejora realmente frente a una solución simple, se definieron dos referencias; **la más fuerte es la que cualquier modelo debe superar.**

Tabla 10: Baselines

Baseline	Qué hace	Para qué sirve
B1 – Trivial	Predice siempre la clase mayoritaria (no cancela)	Piso absoluto (“sin información”)
B2 – Regla heurística	Predice fuga si el contrato es mensual y la antigüedad es de seis meses o menos	¿Basta con una regla de negocio sencilla?

La regla heurística se inspiró en el análisis exploratorio, por lo que se interpreta como una referencia descriptiva y no como una evaluación completamente ciega.

7.2. Métricas

- **PR-AUC:** resume qué tan bien ordena el modelo a los clientes en riesgo. Es la métrica principal porque la clase fuga es minoritaria.
- **Recall:** de cada 100 clientes que cancelan, cuántos detecta el modelo.
- **Precision:** de cada 100 clientes señalados como riesgo, cuántos realmente cancelan.
- **F1:** equilibrio entre las dos anteriores.
- **ROC-AUC:** capacidad general de separar las dos clases.
- **Accuracy:** se reporta solo como referencia, porque con este desbalance resulta engañosa.

7.3. Modelos

Se compararon dos modelos con los mismos datos, la misma división y la misma preparación, usando su configuración preliminar:

- **Regresión logística:** un modelo lineal sencillo y fácil de interpretar. Sirve como punto de partida.
- **Random Forest:** combina muchos árboles de decisión (Breiman, 2001). Se eligió porque puede captar relaciones que no son una línea recta, por ejemplo que el efecto de la antigüedad dependa del contrato. Se usaron 100 árboles con profundidad máxima de 10.

Ambos se entrenaron con ponderación balanceada de clases, mediante el parámetro `class_weight`, para compensar el desbalance, y con un umbral de decisión de 0.50.

7.4. Resultados en validación

Tabla 11: Métricas en *validation* ($n = 1,056$)

Modelo	Accuracy	Precision	Recall	F1	ROC	PR-AUC
Regresión logística	0.7405	0.5067	0.8143	0.6247	0.8448	0.6313
Random Forest	0.7689	0.5464	0.7571	0.6347	0.8417	0.6327




Figura 6: Curvas ROC y precision-recall de los dos modelos en validación

Fuente: elaboración propia.

Los dos modelos rinden de forma muy parecida. El Random Forest obtiene un PR-AUC apenas mayor y más precisión; la regresión logística detecta más fugas (81.4 % frente a 75.7 %) a costa de más alertas falsas.

7.5. ¿Diferencias reales o ruido?

La diferencia de PR-AUC entre ambos modelos es de 0.0014, medida sobre una sola partición. Una diferencia tan pequeña puede deberse al azar, por lo que no se interpreta como superioridad de un modelo sobre otro. Esta lectura se refuerza con una comprobación adicional: al ejecutar el mismo código con otra versión de scikit-learn (1.9.1), el Random Forest produce valores distintos y el modelo seleccionado cambia.

Regla de selección. Definida en el código y aplicada de forma automática: se elige el modelo con mayor PR-AUC en validación. Con esa regla queda el **Random Forest** como candidato preliminar. Se reconoce que, en las métricas complementarias, la regresión logística obtiene mayor *recall* y mayor valor económico simulado en validación (42,700 frente a 31,400 dólares); la coherencia de la regla con los criterios de utilidad se revisará en el Trabajo Final.

7.6. Evaluación final en *test*

El *test* se evaluó **una sola vez**, con el modelo ya elegido y reentrenado con *train* y *validation*.

Tabla 12: Métricas en *test* ($n = 1,057$), evaluado una sola vez

Modelo	Accuracy	Precision	Recall	F1	ROC	PR-AUC
B1 – Trivial	0.7342	0.0000	0.0000	0.0000	0.5000	0.2658
B2 – Heurística	0.7635	0.5721	0.4377	0.4960	0.6596	0.3999
Random Forest	0.7833	0.5756	0.7046	0.6336	0.8400	0.6698




Figura 7: Matrices de confusión en *test*: regla heurística y Random Forest

Fuente: elaboración propia.

El Random Forest detecta 198 de las 281 fugas del *test*, frente a 123 de la regla heurística, y deja 83 sin detectar. A cambio, señala a 146 clientes que no cancelaron. El baseline trivial acierta el 73.4 % de las veces sin detectar ninguna fuga, lo que confirma que la exactitud no sirve como guía.

7.7. Simulación económica

Para traducir los errores a términos de negocio, el grupo definió una simulación con los supuestos de la Tabla 13.

Tabla 13: Supuestos de la simulación económica

Resultado	Impacto (USD)	Lectura
Falso negativo	−500	Cliente que cancela sin ser detectado
Falso positivo	−50	Incentivo entregado a quien no pensaba irse
Verdadero positivo	+350	Cliente en riesgo detectado y retenido
Verdadero negativo	0	Cliente que permanece sin ser contactado




Figura 8: Valor económico neto simulado en *test*

Fuente: elaboración propia.

Bajo estos supuestos, no hacer nada equivale a una pérdida de 140,500 dólares y la regla heurística a una pérdida de 40,550, mientras que el modelo alcanza un valor positivo de 20,500. Estos montos son una **simulación**: los costos son supuestos del grupo, se asume que todo cliente en riesgo detectado es retenido, y el resultado cambiaría si cambian esos supuestos.

Tabla 14: Verificación de los criterios de utilidad en *test*

Criterio	Valor	¿Cumple?
PR-AUC > 0.60	0.6698	Sí
PR-AUC mayor que ambos baselines	0.6698 vs. 0.3999 y 0.2658	Sí
$Recall \geq 0.75$	0.7046	No
Valor económico simulado > 0	+20,500 USD	Sí

El modelo supera con claridad a las dos referencias simples, pero la meta de cobertura no se cumple. Se reporta como limitación y no se vuelve a seleccionar modelo a partir del *test*. Aún no puede concluirse que el modelo funcione con clientes de otra empresa o de otro período, ni que las variables asociadas sean la causa de la fuga.

8. ESTADO DEL PROYECTO Y PLAN HACIA EL TF1

8.1. Principales hallazgos

Tabla 15: Principales hallazgos del proyecto

#	Hallazgo	Evidencia
1	Un modelo de aprendizaje mejora de forma clara a la mejor regla simple	PR-AUC de 0.670 frente a 0.400; detecta el 70.5 % de las fugas frente al 43.8 %
2	El contrato y la antigüedad concentran el riesgo	42.7 % de fuga en contratos mensuales; 41.9 % de las fugas con antigüedad ≤ 6 meses
3	La regresión logística rinde casi igual que el Random Forest	PR-AUC de 0.6313 frente a 0.6327 en validación
4	La exactitud es engañosa con este desbalance	El baseline trivial acierta el 73.4 % sin detectar fugas

8.2. Problemas no resueltos y limitaciones

Tabla 16: Limitaciones identificadas

Tema	Limitación	Efecto
Cobertura	<i>Recall</i> de 0.7046 en <i>test</i> , bajo la meta de 0.75	Casi tres de cada diez fugas no se detectan
Validación	Una sola partición; sin validación cruzada	La diferencia entre modelos está dentro del ruido de una partición
Reproducibilidad	El resultado cambia con la versión de scikit-learn	Las versiones de las dependencias deben fijarse
Umbral	Fijo en 0.50	No está ajustado al costo de cada tipo de error
Hiperparámetros	Valores preliminares, sin búsqueda sistemática	Desempeño probablemente subóptimo
Costos	Supuestos del grupo	El valor económico es una simulación, no una ganancia observada
Alcance de los datos	Corte transversal, sin fechas ni historial	No se puede validar con clientes futuros ni afirmar causalidad
Uso del <i>test</i>	Ya se evaluó una vez para el TP1	En el TF1 no debe usarse para decidir nada

8.3. Plan hacia el TF1

Cada tarea parte de una evidencia del TP1.

Tabla 17: Plan de trabajo hacia el Trabajo Final

#	Tarea	Evidencia del TP1	Criterio de éxito
1	Validación cruzada estratificada, con promedio y dispersión de las métricas	Diferencias medidas en una sola partición	Decidir con varias divisiones y no con una sola
2	Búsqueda sistemática de hiperparámetros con registro de experimentos	Hiperparámetros preliminares; los dos modelos empatan	Cada resultado reproducible desde su configuración
3	Ajuste del umbral de decisión y análisis de falsos positivos y negativos	<i>Recall</i> bajo la meta con umbral 0.50	Umbral justificado por los costos, elegido sin usar el <i>test</i>
4	Análisis de sensibilidad de los costos de la simulación	Costos supuestos por el grupo	Conclusión estable ante cambios razonables en los costos
5	Interpretabilidad global y local (importancia de variables, SHAP)	Aún no se explica qué pesa en cada predicción	Explicaciones coherentes con el dominio y precauciones documentadas
6	Técnica adicional solo si resulta pertinente (por ejemplo, segmentación)	El conjunto no tiene datos transaccionales	Se conserva si aporta; si no, se descarta y se documenta
7	Aplicación en Streamlit que carga el <i>pipeline</i> guardado	El enunciado exige una demostración utilizable	Predicción visible y conectada al <i>pipeline</i>
8	Documentación final y dependencias con versiones fijas	El resultado cambia con la versión de scikit-learn	Otra persona puede reproducir el proyecto

Si en el TF1 se realiza una segmentación, sus grupos se describirán como perfiles contruidos con las variables disponibles, y no como valor de vida del cliente, porque el conjunto de datos no contiene información transaccional. La interpretabilidad se abordará con SHAP (Lundberg y Lee, 2017).

9. DECISIONES DE HERRAMIENTAS

Tabla 18: Matriz de decisiones de herramientas

Necesidad	Herramienta elegida	Alternativa considerada	Justificación
EDA	pandas, matplotlib, seaborn	Herramientas de <i>profiling</i> automático	Permiten armar cada gráfico para responder una pregunta concreta y acompañarlo de su interpretación
Preparación	Pipeline y ColumnTransformer	Preprocesamiento manual; <code>get_dummies</code>	Un flujo único aplica los mismos pasos a todos los datos y los ajusta solo con entrenamiento. <code>get_dummies</code> no implica fuga por sí mismo; el riesgo aparece si se aprende información de los datos reservados
Separación de datos	<code>train_test_split</code> estratificado en dos pasos	Una sola división <i>train/test</i>	Con tres particiones la selección del modelo no contamina la evaluación final
Modelamiento	LogisticRegression y RandomForestClassifier	Árbol individual; <i>boosting</i>	Comparan una familia lineal interpretable con un ensamble no lineal, ambas apropiadas para datos en tablas
Baseline	DummyClassifier y regla heurística	Solo DummyClassifier	Una referencia trivial no basta: la regla de negocio es una vara más exigente
Métricas	PR-AUC, <i>recall</i> , <i>precision</i> , F1, ROC-AUC y matriz de confusión	Solo <i>accuracy</i>	La clase fuga es minoritaria; la exactitud no permite decidir
Experimentación (TF1)	Validación cruzada estratificada y búsqueda de hiperparámetros	Un único <i>split</i>	Permite medir estabilidad y reducir la dependencia de una sola partición
Interpretabilidad (TF1)	SHAP e importancia de variables	Solo métricas globales	Permite explicar el comportamiento del modelo a nivel global y local
Despliegue (TF1)	Streamlit con el <i>pipeline</i> guardado	API o aplicación web más compleja	Permite construir una demostración funcional de manera rápida y reproducible

10. DECLARACIÓN DE USO DE IA GENERATIVA

Conforme a lo exigido en el enunciado del proyecto, el grupo declara que utilizó herramientas de IA generativa (ChatGPT, de OpenAI, y Claude, de Anthropic) como apoyo técnico en tareas de revisión de estructura, depuración y organización del código, documentación del repositorio y redacción de borradores de este informe a partir de los resultados generados en los notebooks. El grupo ejecutó el código, verificó los resultados y asume la responsabilidad del análisis, la interpretación y las conclusiones, que puede explicar, justificar y defender con la evidencia generada en el proyecto.

ANEXOS

Anexo A. Repositorio del proyecto

El código, los notebooks, las tablas de resultados y la presentación de este proyecto están en el repositorio público:

<https://github.com/joako-baneado/customer-churn-prediction>

Anexo B. Reproducción de los resultados

Los resultados de este informe se obtienen al ejecutar, desde la raíz del repositorio, el comando `python -m src.train_models`, que genera:

- las particiones en `data/processed/`;
- la tabla `reports/comparacion_modelos_validacion_tp1.csv`;
- la tabla `reports/evaluacion_final_test_tp1.csv`;
- el modelo en `models/pipeline_tp1_seleccionado.joblib`.

Las cifras reportadas corresponden a scikit-learn 1.8.0.

REFERENCIAS

- BlastChar. (s.f.). *Telco customer churn* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774).
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.