


Customer Churn

Sistema predictivo de fuga de clientes

Data Mining Tools · CC209 · NRC 17496 · UPC

Integrantes

Joaquin Basas Requena · Fabian Marcelo Rojas Cuadros
Cielo Luwidka Chavez Merino · Rodrigo Alonso Gamero Vera



1. Problema y criterio de éxito

La pregunta no es “¿qué modelo tiene más accuracy?”, sino “¿qué riesgo podemos detectar de forma útil y reproducible?”

PROBLEMA

¿Qué clientes presentan mayor riesgo de churn y qué variables se asocian con ese riesgo para priorizar intervenciones preventivas?

Unidad de análisis: cliente / contrato individual. Tipo de problema: clasificación binaria supervisada.

26.54%

de los clientes presentan churn

73.46%

retención

Accuracy aislado puede ser engañoso con esta distribución.

CRITERIOS DEL GRUPO

DISCRIMINACIÓN

$\text{PR-AUC} > 0.60$

Baseline por prevalencia ≈ 0.266

COBERTURA

$\text{Recall} \geq 0.75$

Meta interna para la clase Churn

NEGOCIO

$\text{Valor} > 0$

Simulación con costos/beneficios asumidos

Fuente: notebook EDA y criterios de utilidad definidos por el equipo para TP1.

2. Dataset y calidad de datos

Antes de modelar, verificamos estructura, tipos, faltantes y reglas lógicas.

OBSERVACIONES

7,043

clientes

VARIABLES

21

incluye Churn y customerID

DUPLICADOS

0

duplicados completos

CALIDAD

- 11 valores vacíos en TotalCharges.
- Los 11 casos tienen tenure = 0.
- Regla lógica: TotalCharges = 0 para clientes nuevos sin facturación acumulada.
- customerID se excluye del modelamiento.

PROCEDENCIA

Telco Customer Churn

Fuente declarada en el proyecto: muestra pública de IBM, también difundida en Kaggle.


Limitación clave: corte transversal; no contamos con historial transaccional o eventos temporales detallados.

Condición de uso: dataset público para fines académicos; la licencia exacta debe confirmarse en la fuente original.

3. EDA orientado a preguntas

Los patrones se reportan como asociaciones observadas, no como relaciones causales.

Tasa de churn por tipo de contrato



La asociación más fuerte del EDA aparece en contratos mes a mes.

Interpretación: patrón de riesgo para priorización, no evidencia de causalidad.

FIBRA ÓPTICA + SIN TECH SUPPORT

49.4% churn

Subgrupo observado en el EDA

PAGO: ELECTRONIC CHECK

45.3% churn

Mayor tasa entre métodos de pago

ANTIGÜEDAD

Riesgo alto al inicio

Mayor concentración de churn en los primeros meses

Fuente: notebook 01_edu_exploratorio.ipynb. Todas las cifras corresponden a asociaciones descriptivas.


4. Flujo reproducible y prevención de leakage

Separar la selección de modelos de la evaluación final fue una corrección central del TP1.

PARTICIÓN ESTRATIFICADA



PIPELINE DE PREPROCESAMIENTO



Regla clave: Validation decide; Test no participa en la selección del candidato.

Implementación: `scikit-learn Pipeline + ColumnTransformer`. `random_state = 42`.

5. Selección del modelo en Validation

Dos familias distintas, misma preparación y una métrica principal definida antes de mirar Test.

MÉTRICA PRINCIPAL

PR-AUC

porque la clase Churn es minoritaria y nos interesa la calidad del ranking positivo.

Comparación en Validation


Logistic Regression

PR-AUC



0.6313

Recall



0.8143

Random Forest

PR-AUC



0.6327

Recall



0.7571

Candidato preliminar

Random Forest

PR-AUC 0.6327

Ventaja sobre Logistic: +0.0014



Conclusión: desempeño prácticamente equivalente; la selección es preliminar y debe validarse con CV en TF1.

Utilidad simulada Validation: RF +\$31,400 · Logistic +\$42,700

Selección automatizada por mayor PR-AUC en Validation; Test permanece sin consultar hasta después de seleccionar.

6. Evaluación final en Test

Una vez elegido el candidato, se reentrena con Train + Validation y Test se usa para la evaluación final.



Test: 1,057 clientes. El valor económico es una simulación bajo supuestos; no representa ganancia real observada.

7. Lectura crítica del TP1

El resultado es útil porque también deja claro qué todavía no está resuelto.

LO QUE YA FUNCIONA

- PR-AUC final 0.6698: supera la meta interna y a los baselines.
- Pipeline reproducible con preprocesamiento encapsulado.
- Test quedó fuera de la selección del modelo.
- El modelo produce valor positivo bajo la simulación definida.

LIMITACIONES

- Recall final 0.7046: no alcanza la meta interna de 0.75.
- Diferencia RF vs Logistic en Validation es mínima.
- Sin validación cruzada ni búsqueda sistemática de hiperparámetros todavía.
- Costos económicos son supuestos; falta análisis de sensibilidad.

DECISIÓN TP1

Random Forest se mantiene como candidato preliminar, no como “ganador definitivo”.

El siguiente paso no es mirar otra vez Test, sino mejorar la experimentación sobre Train/Validation mediante CV, tuning y análisis de errores.

Idea central: evidencia > métrica aislada.

Cierre TP1: hallazgos actuales, limitaciones y decisiones que se mantienen abiertas hacia TF1.

8. Plan hacia el Trabajo Final

El TP1 deja la base reproducible; TF1 debe convertirla en experimentación sistemática, interpretación y producto.

01

Estabilidad

StratifiedKFold + métricas promedio y dispersión.

02

Optimización

Tuning de hiperparámetros y ajuste de threshold.

03

Interpretabilidad

Importancia / SHAP + análisis de FP y FN.

04

Producto

Segmentación pertinente + despliegue en Streamlit.

TAKEAWAY

Ya tenemos un flujo que supera baselines y produce evidencia reproducible; el objetivo del TF1 es demostrar estabilidad, mejorar Recall y convertir el modelo en una herramienta interpretable y desplegable.

Transparencia: se utilizó IA generativa como apoyo para organización, redacción y revisión de código/documentación; el equipo validó los análisis, decisiones y conclusiones.

Apéndice · Resultados reproducibles

Valores de referencia para preguntas durante la exposición.

Conjunto	Modelo	PR-AUC	Recall	Valor simulado
Validation	Logistic Regression	0.6313	0.8143	+\$42,700
Validation	Random Forest	0.6327	0.7571	+\$31,400
Test	Dummy	0.2658	0.0000	−\$140,500
Test	Heurístico	0.3999	0.4377	−\$40,550
Test	Random Forest seleccionado	0.6698	0.7046	+\$20,500

Nota metodológica El Test se usó después de seleccionar Random Forest en Validation. No se vuelve a comparar Logistic vs RF usando Test.

Artefactos: reports/comparacion_modelos_validacion_tp1.csv y reports/evaluacion_final_test_tp1.csv.